

Statistique descriptive

1. Généralités et principales définitions

- La **statistique** désigne à la fois un ensemble de données et l'ensemble des activités consistant à collecter ces données, à les traiter et à les interpréter.
- Les **statistiques**, l'ensemble des données numériques, interviennent pratiquement dans tous les domaines d'activité : gestion financière (états, banques, assurances, etc.), démographie, contrôles de qualité, études de marché, sciences expérimentales (biologie, psychologie, etc.).
- Le traitement des données, pour en dégager un certain nombre de renseignements **qualitatifs** ou **quantitatifs** à des fins de comparaison, s'appelle la **statistique descriptive**.
- L'ensemble sur lequel porte l'activité statistique s'appelle la **population**. Elle est généralement notée Ω pour rappeler la notation des probabilités mais par exemple dans la théorie des sondages elle est notée U (comme Univers).
- Un groupe restreint, ou sous-ensemble, issu de la population, est appelé **échantillon**. Pour définir un **échantillon aléatoire**, une méthode consiste à prélever, au hasard, un sous-ensemble en utilisant, par exemple, des tables de nombres au hasard.
- Les éléments qui constituent la population sont appelés les **individus** ou encore les **unités statistiques**.

Exemple 1.

Une usine fabrique des tiges métalliques utilisées dans l'assemblage de certaines structures. Pour étudier la résistance à la traction de ces tiges, on mesure cette résistance pour un lot de 100 tiges.

Propriété étudiée : la résistance à la traction de tiges métalliques.

Population statistique : l'ensemble des 100 tiges ou des 100 mesures.

Unité statistique : chacune des tiges ou chacune des 100 mesures.

- Les caractéristiques étudiées sur les individus d'une population sont appelées les **caractères**. Une **variable statistique** ou **aléatoire** est un caractère faisant l'objet d'une étude statistique. Une **variable quantitative** est appelée :

- **discrète** si elle prend un nombre fini de valeurs souvent entières,
- **continue** si elle prend toutes les valeurs d'un intervalle fini ou infini.

Une variable statistique ou aléatoire est notée par une **lettre majuscule** X, Y , et les valeurs qu'elle prend par des **lettres minuscules** $x_1, x, \dots, y_1, y_2, \dots$

Nous considérons plusieurs types de caractères :

1. les **caractères qualitatifs**, exemple : profession, adresse, sexe, numéro de téléphone, etc. Le caractère est un critère de classement, il peut présenter plusieurs situations différentes, (plusieurs **modalités**). Les deux modalités du caractère « sexe » sont : masculin et féminin. On distingue en général :
 - (a) les **caractères qualitatifs nominaux** : les modalités possibles ne présupposent aucun classement.
 - (b) les **caractères qualitatifs ordonnés** : les modalités possibles peuvent être rangées dans un ordre.
2. les **caractères quantitatifs**, les modalités sont **mesurables** ou **repérables**. Nous distinguons :

- (a) les **caractères simples** ou **univariés** : leur mesure sur un individu produit un seul nombre. L'ensemble de leurs valeurs est donc une partie de $\mathbb{R}$. Exemple : taille, poids, salaire, etc.
- (b) les **caractères multiples** : leur mesure sur un individu produit une suite finie de nombres. L'ensemble de leurs valeurs est donc une partie de $\mathbb{R}^n$. Exemple : relevé de notes d'un étudiant, fiche de salaire, etc.

2. Description d'une série statistique

Si X est un caractère quantitatif simple, la suite finie $X(\Omega) = (X_1, X_2, \dots, X_p)$ des valeurs atteintes par le caractère (ou données brutes) est un ensemble fini $(x_1, x_2, \dots, x_p)$.

2.1. Distribution statistique discrète

Définition 1.

Soit une série statistique $(x_i, n_i)_{1 \leq i \leq p}$. Nous appelons

1. **effectif de la valeur** x_i : le nombre n_i de fois que la valeur x_i est prise.
2. **effectif cumulé** en x_i : la somme $\sum_{j=1}^i n_j$
3. **fréquence de la valeur** x_i : le rapport $f_i = \frac{n_i}{N}$ de l'effectif de x_i à l'effectif total $N = \sum_{i=1}^p n_i$.
4. **fréquence cumulée en** x_i : la somme $\sum_{j=1}^i f_j$

La série statistique $(x_i, n_i)_{1 \leq i \leq p}$ ou $(x_i, f_i)_{1 \leq i \leq p}$ est appelée **distribution statistique discrète**.

2.2. Distribution statistique continue

Lorsque le caractère quantitatif comprend un grand nombre de valeurs, nous préférons regrouper les valeurs en intervalles appelées **classes** pour rendre la statistique plus lisible. Nous partageons alors l'ensemble C des valeurs du caractère en classes $[a_i, a_{i+1}[$, $a_i < a_{i+1}$.

Définition 2.

Soit une série statistique $([a_i, a_{i+1}[$, $n_i)_{1 \leq i \leq p}$. Nous appelons

1. **effectif de la valeur** $[a_i, a_{i+1}[$: le nombre n_i de valeurs prises dans $[a_i, a_{i+1}[$.
2. **effectif cumulé** en a_i : le nombre de valeurs prise dans $] -\infty, a_i]$
3. **fréquence de** $[a_i, a_{i+1}[$: le rapport $f_i = \frac{n_i}{N}$
4. **fréquence cumulée en** a_i : la somme $\sum_{j=1}^i f_j$

La série statistique $([a_i, a_{i+1}[$, $n_i)_{1 \leq i \leq p}$ ou $([a_i, a_{i+1}[$, $f_i)_{1 \leq i \leq p}$ est appelée **distribution statistique groupée** ou **continue**.

2.3. Tableaux statistiques

Sauf cas exceptionnels, les données statistiques sont présentées sous forme de tableau. D'une part, cela permet d'appréhender l'information qui est synthétisée et d'autre part facilite ou rend possible les calculs.

Tableau statistique pour une variable qualitative

Modalités ou caractères	Effectifs n_i	Fréquences f_i	Pourcentages p_i	Fréquences cumulées F_i
Catégorie 1	n_1	f_1	p_1	F_1
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
Catégorie i	n_i	$f_i = \frac{n_i}{N}$	$p_i = 100f_i$	$F_i = \sum_{j=1}^i f_j$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
Catégorie m	n_m	f_m	p_m	$F_m = 1$
	Total=N	Total=1	Total=100	

Tableau statistique pour une variable quantitative discrète

Valeurs de la variable X	Effectifs n_i	Fréquences f_i	Pourcentages p_i	Fréquences cumulées F_i
x_1	n_1	f_1	p_1	F_1
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_i	n_i	$f_i = \frac{n_i}{N}$	$p_i = 100f_i$	$F_i = \sum_{j=1}^i f_j$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_m	n_m	f_m	p_m	$F_m = 1$
	Total=N	Total=1	Total=100	

Tableau statistique pour une variable quantitative continue

Classes	Centres de classe c_i	Effectifs n_i	Fréquences f_i	Pourcentages p_i	Fréquences cumulées F_i
$[a_1, a_2[$	c_1	n_1	f_1	p_1	F_1
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$[a_i, a_{i+1}[$	$c_i = \frac{a_i + a_{i+1}}{2}$	n_i	$f_i = \frac{n_i}{N}$	$p_i = 100f_i$	$F_i = \sum_{j=1}^i f_j$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
$[a_m, a_{m+1}[$	c_m	n_m	f_m	p_m	$F_m = 1$
		Total=N	Total=1	Total=100	

Mini-exercices.

- Le tableau suivant donne la distribution des ménages en France en 2010

Nombre de personnes du ménage	Pourcentage des ménages
1	34.0
2	31.1
3	14.5
4	12.2
5	4.6
6 et plus	3.6
Nombre total des ménages	27 106.5 en milliers

Construire le tableau statistique en calculant la population comptée dans cette étude.

2. Le tableau suivant donne un extrait de la table de mortalité de la génération féminine française de 1899.

Âge exact	0	1	2	3	4	5	6	7
Survivants à l'âge exact	100 000	84 883	82 247	80 843	79 995	79 186	78 763	78 411

Présenter le tableau statistique de la variable « âge du décès » sous sa forme habituelle, puis donner la signification concrète de chacune des colonnes du tableau statistique obtenu.

3. Représentation graphique

3.1. Représentation des caractères qualitatifs

Les cartogrammes

Les **cartogrammes** représentent les valeurs ou variations d'une grandeur sur un territoire géographique en assignant à chaque zone – département, région – ses caractéristiques. Pour cela, on utilise des fonds de cartes pour représenter les variables.


Les diagrammes en colonnes

Le **diagramme en tuyaux d'orgue**, en **barres** ou en **colonnes** est constitué d'une suite de rectangles dont les hauteurs sont proportionnelles à l'effectif (ou à la fréquence) de la variable et dont les bases sont identiques. La représentation peut être horizontale ou verticale.

Exemple 2.


Tableau de la distribution des achats de boissons non alcoolisées.

Boissons non alcoolisées	Effectifs n_i	Fréquences f_i	Pourcentages p_i	Fréquences cumulées F_i
Coca cola	19	0.38	38	0.38
Coca light	8	0.16	16	0.54
Dr Pepper	5	0.10	10	0.64
Pepsi	13	0.26	26	0.90
Sprite	5	0.10	10	1
	Total=50	Total=1	Total=100	



Les diagrammes circulaires

Le **diagramme en secteurs** ou en **camembert** visualise la part relative des catégories de la variable sur une population. Le disque représente l'ensemble de la population, les différentes modalités seront représentées par des secteurs dont la surface est proportionnelle aux effectifs ou aux fréquences.



3.2. Représentation des caractères quantitatifs

Représentations graphiques pour une distribution statistique discrète

- Le **diagramme en feuilles**, décompose une donnée numérique en deux parties :
 - la tige qui comprend le premier ou les deux premiers chiffres,
 - la feuille qui comprend les autres chiffres.

Exemple 3.

Le tableau suivant donne le poids en grammes de 25 éprouvettes.

250	253	256	258	260	261	263	265	270
271	272	273	274	276	276	279	279	281
284	285	286	287	288	290	290		

Comme tige, on choisit les deux premiers chiffres de chaque mesure, c'est-à-dire 25, 26, 27, 28 et 29. Les feuilles sont alors constituées du dernier chiffre de la mesure :

25	0	3	6	8				
26	0	1	3	5				
27	0	1	2	3	4	6	6	9
28	1	4	5	6	7	8		
29	0	0						


Le diagramme indique que le poids moyen se situe entre 270 et 280 g et qu'il doit être voisin de 270 g.

- Le **diagramme en bâtons des effectifs** (resp. **des fréquences**) d'une distribution statistique discrète est constitué d'une suite de segments verticaux d'abscisses x_i dont la longueur est proportionnelle à l'effectif (resp. la fréquence) de x_i .


Exemple 4.

Tableau de la distribution des familles selon le nombre d'enfants.

Nombre d'enfants	Effectifs n_i	Fréquences f_i	Pourcentages p_i	Fréquences cumulées F_i
0	7 000 000	0.446	44.6	44.6%
1	3 600 000	0.229	22.9	67.5%
2	3 300 000	0.210	21.0	88.5%
3	1 300 000	0.083	8.3	96.8%
4 et +	500 000	0.032	3.2	100%
	Total=15 700 000	Total=1	Total=100	



- Le **polygone des effectifs** (resp. **des fréquences**) d'une distribution statistique discrète est obtenu à partir du diagramme en bâtons des effectifs (resp. des fréquences) en joignant par un segment les sommets des bâtons.
- En remplaçant dans la définition précédente le mot effectifs (resp. fréquences) par effectifs cumulés (resp. fréquences cumulées), nous obtenons le **polygone des effectifs cumulés** (resp. des **fréquences cumulées**).




Représentations graphiques pour une distribution statistique continue

- **L'histogramme** est la représentation graphique d'une distribution statistique continue. Deux cas se distinguent :
 1. Dans le cas où les **amplitudes des classes sont égales**, cet histogramme est constitué d'un ensemble de rectangles dont la largeur est égale à a , l'amplitude de la classe, et la hauteur égale à $K \times n_j$ où n_j est l'effectif de la classe et K est un coefficient arbitraire (on peut prendre $K = 1$ pour simplifier), de sorte que l'aire totale sous l'histogramme est égale $K \times N \times a$ où N est l'effectif total.
 2. Dans le cas de classes d'**amplitudes inégales** $k_j \times a$, multiples entiers de l'une d'entre elles a , nous convenons, pour conserver le résultat précédent, de prendre pour hauteur du rectangle de la classe numéro j le quotient $\frac{K \times n_j}{k_j}$.


Exemple 5.

Tableau des surfaces agricoles utiles (SAU)

Classes en (ha)	Centres c_i	Amplitudes a_i	Effectifs n_i	f_i	$(f_i \times 100) / a_i$	F_i
[0,5[	2.5	5	500	8.3%	166.7	8.3%
[5,15[	10	10	15 000	25.0%	250.0	33.3%
[15,25[	20	10	11 000	18.3%	183.3	51.7%
[25, 50[	37.5	25	20 000	33.3%	133.3	85.0%
[50, 100[	75	50	7 000	11.7%	23.3	96.7%
[100,150[	25	50	2 000	3.3%	6.7	100%
			Total=60 000	Total=100%		




- Le **polygone des effectifs** ou des **fréquences** d'une distribution statistique continue est obtenu en joignant dans l'histogramme de cette distribution les milieux des côtés horizontaux supérieurs.



- Le **polygone des fréquences cumulées** d'une distribution statistique continue est la représentation graphique de la fonction définie sur chaque intervalle $[a_i, a_{i+1}[$, $1 \leq i \leq p$, par

$$f(x) = \sum_{j=1}^{i-1} f_j + \frac{x - a_i}{a_{i+1} - a_i} f_i$$



Mini-exercices.

- L'évolution des émissions de gaz à effet de serre (GES) en million de tonnes est donnée dans le tableau suivant

GES \ Année	2000	2005	2008	2009
CO ₂	409	420	391	373
CH ₄	68	66	66	65
N ₂ O	78	68	66	62

Représenter graphiquement l'évolution de l'importance relative des divers GES.

- Représenter la distribution statistique discrète $\{(1, 2), (2, 3), (3, 4), (4, 1), (5, 6), (6, 5), (7, 2), (8, 3), (9, 1), (10, 1)\}$:
 - à l'aide du diagramme en bâtons des effectifs ;
 - en superposant le diagramme en bâtons et le polygone des fréquences ;
 - en superposant le diagramme en bâtons et le polygone des effectifs cumulés.
- Représenter la distribution statistique groupée suivante $\{([1, 3], 4), ([3, 4], 8), ([4, 5.5], 10), ([5.5, 6], 14), ([6, 8], 20), ([8, 10], 12), ([10, 11], 9), ([11, 12.5], 3)\}$:

- (a) à l'aide d'un histogramme des fréquences ;
- (b) en superposant l'historgramme des fréquences et son polygone des fréquences ;
- (c) à l'aide du polygone des fréquences cumulées.

4. Diverses caractéristiques

4.1. Caractéristiques de position

- Le **mode**, M_o , correspond à la valeur de la variable pour laquelle la fréquence est la plus élevée. Dans le cas d'une variable non classée, caractère qualitatif ou variable discrète, la détermination du mode est immédiate, c'est la valeur ayant le plus grand effectif ou la plus grande fréquence. Pour une distribution statistique continue, une classe modale, est une classe de **densité**, c'est-à-dire de rapport fréquence/amplitude, maximale. La distribution est **unimodale** si elle a un seul mode. Si elle en a plusieurs, elle est **multimodale** (**bimodale**, **trimodale**, etc.).
- Soit m et d les parties entière et décimale de $\frac{N+1}{2}$. La **médiane**, M_e , d'une série statistique est définie par $M_e = x_m + d(x_{m+1} - x_m)$, où x_m signifie la $m^{\text{ième}}$ valeur lorsque la série statistique est rangée par ordre croissant.
- Soit m et d les parties entière et décimale de $\frac{N+1}{4}$. Le **premier quartile**, Q_1 , d'une série statistique est défini par $Q_1 = x_m + d(x_{m+1} - x_m)$
Soit m' et d' les parties entière et décimale de $\frac{3(N+1)}{4}$. Le **troisième quartile**, Q_3 , d'une série statistique est défini par $Q_3 = x_{m'} + d'(x_{m'+1} - x_{m'})$.

Exemple 6.

Tableau donnant le salaire mensuel de départ d'un échantillon de 12 diplômés d'une école de commerce.

Diplômé	1	2	3	4	5	6	7	8	9	10	11	12
Salaire en \$	3850	3950	4050	3880	3755	3710	3890	4130	3940	4325	3920	3880

Le seul salaire mensuel initial qui apparaît plus d'une fois est 3 880\$, c'est le mode.

Rang	1	2	3	4	5	6	7	8	9	10	11	12
Ordre Croissant	3710	3755	3850	3880	3880	3890	3920	3940	3950	4050	4130	4325

Or $m = E\left(\frac{12+1}{2}\right) = 6$ et $d = D\left(\frac{12+1}{2}\right) = 0.5$. Alors la médiane est

$$M_e = x_6 + 0.5(x_7 - x_6) = 3890 + 0.5(3920 - 3890) = 3905\$.$$

Aussi $m' = E\left(\frac{12+1}{4}\right) = 3$ et $d' = D\left(\frac{12+1}{4}\right) = 0.25$. Alors le 1^{er} quartile est

$$Q_1 = x_3 + 0.25(x_4 - x_3) = 3850 + 0.25(3880 - 3850) = 3857.5\$.$$

De même $m'' = E\left(\frac{3(12+1)}{4}\right) = 9$ et $d' = D\left(\frac{3(12+1)}{4}\right) = 0.75$. Alors le 3^e quartile est

$$Q_3 = x_9 + 0.75(x_{10} - x_9) = 3950 + 0.75(4050 - 3950) = 4025\$.$$

Le **diagramme en boîte** - autrement appelé **boîte à moustaches**, « *box plot* » ou « *box and whisker plot* » - donne une représentation très simple de la distribution. Elle consiste en une boîte rectangulaire, dont les deux extrémités sont les quartiles. On représente aussi la médiane par un trait dans la boîte ainsi que les valeurs extrêmes par des points.




FIGURE 1.1 – Boîte-à-moustaches

- La **moyenne arithmétique**, $\bar{x}$ (si le caractère est noté par X), d'une distribution statistique **discrète** est le nombre réel défini par

$$\bar{x} = \frac{1}{N} \sum_{i=1}^p n_i x_i = \sum_{i=1}^p f_i x_i$$

Pour une distribution statistique **continue**, la moyenne se calcule par $\bar{x} = \frac{1}{N} \sum_{i=1}^p n_i c_i = \sum_{i=1}^p f_i c_i$.

Il existe d'autres types de moyenne, comme la moyenne **géométrique**, la moyenne **harmonique**, etc. La moyenne arithmétique est facile à calculer et l'on peut procéder à un changement d'**origine** et d'**échelle**. On pose pour toutes les données, $y_i = ax_i + b$, a et b étant des constantes ; on obtient : $\bar{y} = a\bar{x} + b$.

4.2. Caractéristiques de dispersion

- L'**étendue**, notée e , est la différence : $e = \max(x_i) - \min(x_i)$.
- L'**étendue interquartile**, notée EIQ , est la différence entre les quartiles Q_3 et Q_1 , donc $EIQ = Q_3 - Q_1$.
- La **variance** d'une distribution statistique **discrète** est définie par

$$\text{Var}(x) = \sigma_x^2 = \frac{1}{N} \sum_{i=1}^p n_i (x_i - \bar{x})^2 = \sum_{i=1}^p f_i (x_i - \bar{x})^2 = \sum_{i=1}^p f_i x_i^2 - \bar{x}^2$$

Pour une distribution statistique **continue**, la variance se calcule par

$$\text{Var}(x) = \sigma_x^2 = \frac{1}{N} \sum_{i=1}^p n_i (c_i - \bar{x})^2 = \sum_{i=1}^p f_i (c_i - \bar{x})^2 = \sum_{i=1}^p f_i c_i^2 - \bar{x}^2,$$

Si $y_i = ax_i + b$ alors $\text{Var}(y) = a^2 \text{Var}(x)$. Un changement d'origine n'a donc **aucune influence**.

- L'**écart-type** est égal à $\sqrt{\text{Var}(x)}$
- Le **moment centré d'ordre r** est défini par

$$m_r = \underbrace{\sum_{i=1}^p f_i (c_i - \bar{x})^r}_{\text{cas continu}} \quad \text{ou} \quad m_r = \underbrace{\sum_{i=1}^p f_i (c_i - \bar{x})^r}_{\text{cas continu}}$$

Pour faciliter le calcul des moments, on utilisera un tableau comme suit :

x_i ou c_i	f_i	$f_i \cdot x_i$	$(x_i - \bar{x})^r$	$f_i (x_i - \bar{x})^r$
x_1	f_1	$f_1 \cdot x_1$	$(x_1 - \bar{x})^r$	$f_1 (x_1 - \bar{x})^r$
x_2	f_2	$f_2 \cdot x_2$	$(x_2 - \bar{x})^r$	$f_2 (x_2 - \bar{x})^r$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_p	f_p	$f_p \cdot x_p$	$(x_p - \bar{x})^r$	$f_p (x_p - \bar{x})^r$
Total = 1	$\bar{x}$			$m_r = \sum_{i=1}^p f_i (x_i - \bar{x})^r$

Exemple 7.

Tableau des surfaces agricoles utiles (SAU)

Classes en (ha)	Effectifs n_i	Centres c_i	Amplitudes a_i	f_i	$f_i \times c_i$	F_i	$f_i \times c_i^2$
[0,5 [	5000	2.5	5	0.083	0.208	8.3%	0.519
[5,15 [	15 000	10	10	0.250	2.500	33.3%	25.000
[15,25 [	11 000	20	10	0.183	3.677	51.7%	73.200
[25, 50[	20 000	37.5	25	0.333	12.500	85.0%	468.281
[50, 100[	7 000	75	50	0.117	8.750	96.7%	658.125
[100,150 [	2 000	125	50	0.033	4.167	100%	515.625
	Total=60 000			Total=1	$\bar{x} = 31.8$		Total=1740.75

La médiane est obtenue par extrapolation : $M_e = b_i + a_i \frac{50 - F_i}{F_{i+1} - F_i}$.

La médiane est $M_e = 15 + 10 \frac{50 - 33.3}{18.3} = 24.1 \text{ ha}$.

Le premier quartile est $Q_1 = 5 + 10 \frac{25 - 8.3}{25} = 11.7 \text{ ha}$.

Le troisième quartile est $Q_3 = 25 + 25 \frac{75 - 51.7}{33.3} = 42.5 \text{ ha}$.

L'étendue interquartile est $EIQ = Q_3 - Q_1 = 29.8 \text{ ha}$.

La variance est $\text{Var}(x) = \sum_i f_i \cdot c_i^2 - \bar{x}^2 = 1740.75 - (31.8)^2 = 729.51$.

L'écart-type est $\sigma_x = \sqrt{\text{Var}(x)} = 27.01 \text{ ha}$

4.3. Caractéristiques de forme

- Une **distribution est symétrique** si les valeurs de la variable statistique sont également distribuées de part et d'autre d'une valeur centrale. Pour une distribution symétrique :

$$\text{mode} = \text{médiane} = \text{moyenne arithmétique}$$

- Le **coefficient d'asymétrie ou skewness** est défini par

$$\gamma_1 = \frac{m_3(x)}{(\sigma_x)^3}$$

- Le **coefficient d'aplatissement ou kurtosis** est défini par

$$\gamma_2 = \frac{m_4(x)}{(\sigma_x)^4}$$

Ces deux coefficients sont principalement utilisés pour vérifier qu'une distribution est proche d'une **distribution normale** (loi de **Laplace-Gauss**) ; en effet, pour une telle loi, le coefficient d'aplatissement est égal à 3 et le coefficient d'asymétrie à 0. Selon la valeur de ces coefficients, on peut donner quelques caractéristiques sur la forme de la distribution :

- si $\gamma_1 > 0$, la distribution est étalée vers la droite,
- si $\gamma_1 < 0$, la distribution est étalée vers la gauche,
- si $\gamma_1 = 0$, on ne peut pas conclure que la distribution est symétrique mais la réciproque est vraie,
- si $\gamma_2 > 3$, la distribution est moins aplatie qu'une distribution gaussienne,
- si $\gamma_2 < 3$, la distribution est plus aplatie qu'une distribution gaussienne.

4.4. Caractéristiques de concentration

Ces caractéristiques sont utilisées pour une grandeur positive cumulative telle que le revenu, la consommation, etc.

- La **courbe de concentration** traduit le pourcentage des individus consommant moins de x_i à la contribution de ces individus à la moyenne $\bar{x}$ de la masse totale M . La **courbe de concentration de Lorenz** visualise graphiquement la concentration. La construction de cette courbe nécessite la connaissance de la distribution des effectifs et de celle de la variable X . Plus la distribution de X est inégalement répartie, plus la courbe de concentration s'éloigne de la **première bissectrice**, la première bissectrice traduisant l'équi-répartition.
- L'**indice de Gini**, I_G , associé à la courbe de Lorenz mesure l'importance de la concentration. Pour un échantillon de taille n , cet indice est donné par :

$$I_G := \frac{1}{n(n-1)\bar{x}} \sum_{i=1}^n \sum_{j=i+1}^n |x_i - x_j|.$$

- La **courbe de Lorenz** se construit en inscrivant en abscisses le pourcentage F_i cumulé des effectifs et en ordonnée le pourcentage cumulé G_i des valeurs la variable statistique. Les calculs nécessaires pour obtenir les différentes caractéristiques sont grandement facilités par la construction du tableau statistique

Variable x_i ou c_i	Fréquences f_i	Fréquences cumulées F_i		g_i	G_i	$f_i (G_{i-1} + G_i)$
x_1	f_1	$F_1 = f_1$	$f_1 x_1$	$g_1 = \frac{f_1 x_1}{\bar{x}}$	$G_1 = g_1$	$f_1 G_1$
x_2	f_2	$F_2 = f_1 + f_2$	$f_2 x_2$	$g_2 = \frac{f_2 x_2}{\bar{x}}$	$G_2 = g_1 + g_2$	$f_2 (G_1 + G_2)$
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_p	f_p	$F_p = \sum_{i=1}^p f_i = 1$	$f_p x_p$	$g_p = \frac{f_p x_p}{\bar{x}}$	$G_p = \sum_{i=1}^p g_i = 1$	$f_p (G_{p-1} + G_p)$
	Total = 1		$\bar{x}$	Total = 1		$\sum_{i=1}^p f_i (G_{i-1} + G_i)$

L'indice I_G résume la concentration à l'aide d'un seul nombre

$$I_G = 1 - \sum_{i=1}^p f_i (G_{i-1} + G_i).$$

L'indice I_G varie de 0 à 1, plus il est proche de 0 plus la concentration est faible, s'il est proche de 1 la concentration est forte. L'indice de concentration est un nombre sans dimension, indépendant de l'unité choisie.




FIGURE 1.2 – Courbe de Lorenz

Mini-exercices.

- Établir, pour le tableau ci-dessous (nombre d'heures travaillées par semaine des personnes ayant un emploi à plein temps dans les États membres en 2006)

Pays	Durée en h	Pays	Durée en h	Pays	Durée en h	Pays	Durée en h
Allemagne	41.70	Estonie	41.50	Italie	41.30	Pologne	42.90
Autriche	44.10	Finlande	40.50	Lettonie	43.00	Portugal	41.60
Belgique	41.00	France	41.00	Lituanie	39.80	Tchèque	42.70
Chypre	41.80	Grèce	44.10	Luxembourg	40.90	Royaume-Uni	43.10
Danemark	40.50	Hongrie	41.00	Malte	41.20	Slovaquie	41.60
Espagne	42.20	Irlande	40.70	Pays-Bas	40.80	Slovénie	42.50
Suède	41.10						

- la moyenne, la médiane, le minimum, le maximum, le premier et troisième quartile,
 - l'étendue, l'étendue interquartile, l'écart-type,
 - les coefficients d'asymétrie et les coefficients d'aplatissement,
 - et la boîte de dispersion.
- Le tableau ci-dessous donne la répartition des SAU (surface agricole utilisée) viticoles en hectares

Classes	[0; 5[	[5; 10[	[10; 20[	[20; 50[	[50; 100[	[100; 150[
Fréquences en %	8.3	25	18.4	33.3	11.7	3.3



Calculer l'indice de Gini puis tracer la courbe de Lorenz.

5. Statistique descriptive bivariable

Soit (X, Y) une distribution statistique d'un couple de caractères sur une population d'effectif N . Notons $(x_1, x_2, \dots, x_p)$, et $(y_1, y_2, \dots, y_q)$ les valeurs distinctes observées pour X et Y

5.1. Distribution conjointe

- L'**effectif du couple** (x_i, y_j) est égal au nombre $n_{i,j}$ de couples de valeurs égaux à (x_i, y_j) .
- La **fréquence du couple** (x_i, y_j) est égal au nombre $f_{i,j} = \frac{n_{i,j}}{N}$
- $((x_i, y_j), n_{i,j})_{\substack{1 \leq i \leq p \\ 1 \leq j \leq q}}$ et $((x_i, y_j), f_{i,j})_{\substack{1 \leq i \leq p \\ 1 \leq j \leq q}}$ sont la **distribution des effectifs** et la **distribution des fréquences** du couple (X, Y) .

5.2. Distributions marginales

- L'**effectif marginal** de x_i est égal au nombre $n_{i,\bullet} = \sum_{j=1}^q n_{i,j}$.
- L'**effectif marginal** de y_j est égal au nombre $n_{\bullet,j} = \sum_{i=1}^p n_{i,j}$.
- La **fréquence marginale** de x_i est égale au nombre $f_{i,\bullet} = \sum_{j=1}^q f_{i,j}$.
- La **fréquence marginale** de y_j est égale au nombre $f_{\bullet,j} = \sum_{i=1}^p f_{i,j}$.
- $((x_i, y_j), n_{i,\bullet})_{1 \leq i \leq p}$ et $((x_i, y_j), n_{\bullet,j})_{1 \leq j \leq q}$ sont appelées les **distributions marginales des effectifs** du couple (X, Y) .
- $((x_i, y_j), f_{i,\bullet})_{1 \leq i \leq p}$ et $((x_i, y_j), f_{\bullet,j})_{1 \leq j \leq q}$ sont appelées les **distributions marginales des fréquences** du couple (X, Y) .

5.3. Indépendance et distributions conditionnelles

- Y est **indépendant** de X si la distribution des fréquences de Y dans la sous-population Ω_i des individus pour lesquels la valeur de X est x_i , ne dépend pas de i .
- La fraction $\frac{n_{i,j}}{n_{i,\bullet}} = \frac{f_{i,j}}{f_{i,\bullet}}$ représente la **fréquence conditionnelle** de la valeur y_j sachant x_i .
- La fraction $\frac{n_{i,j}}{n_{\bullet,j}} = \frac{f_{i,j}}{f_{\bullet,j}}$ représente la **fréquence conditionnelle** de la valeur x_i sachant y_j .
- La distribution $\left(y_j, \frac{f_{i,j}}{f_{\bullet,j}}\right)_{1 \leq j \leq q}$ est appelée la **distribution conditionnelle des fréquences** de Y sachant que $X = x_i$.
- La distribution $\left(x_i, \frac{f_{i,j}}{f_{i,\bullet}}\right)_{1 \leq i \leq p}$ est appelée la **distribution conditionnelle des fréquences** de X sachant que $Y = y_j$.

Croisement de deux variables (idem. caractères)

Var. 1 \ Var. 2	y_1	y_i	y_p	Eff. marg. de Var. 1
x_1	n_{11}	n_{1i}	n_{1p}	$n_{1\bullet} = \sum_{j=1}^p n_{1j}$
x_i	n_{i1}	n_{ii}	n_{ip}	$n_{i\bullet} = \sum_{k=1}^p n_{ik}$
x_p	n_{p1}	n_{pi}	n_{pp}	$n_{p\bullet} = \sum_{j=1}^p n_{pj}$
Eff. marg. de Var. 2	$n_{\bullet 1} = \sum_{i=1}^p n_{i1}$	$n_{\bullet i} = \sum_{k=1}^p n_{ki}$	$n_{\bullet p} = \sum_{i=1}^p n_{ip}$	Total=N

Principe des calculs dans un tableau de contingence.

$\times$	y_j	Total	B_i	D_i	Moy.	Var.
x_i	n_{ij}	$n_{i\bullet} = \sum_{j=1}^p n_{ij}$	$\sum_{j=1}^p n_{ij} \cdot y_j$	$\sum_{j=1}^p n_{ij} \cdot y_j^2$	$\bar{y}_{ i} = \frac{B_i}{n_{i\bullet}}$	$\sigma_{y_{ i}}^2 = \frac{D_i}{n_{i\bullet}} - \frac{B_i^2}{n_{i\bullet}^2}$
Total	$n_{\bullet j} = \sum_{i=1}^p n_{ij}$	N	B	D	$\bar{y} = \frac{B}{N}$	$\sigma_y^2 = \frac{D}{N} - \frac{B^2}{N^2}$
A_j	$\sum_{i=1}^p n_{ij} \cdot x_i$	A				
C_j	$\sum_{i=1}^p n_{ij} \cdot x_i^2$	C				
Moy.	$\bar{x}_{ j} = \frac{A_j}{n_{\bullet j}}$	$\bar{x} = \frac{A}{N}$				
Var.	$\sigma_{x_{ j}}^2 = \frac{C_j}{n_{\bullet j}} - \frac{A_j^2}{n_{\bullet j}^2}$	$\sigma_x^2 = \frac{C}{N} - \frac{A^2}{N^2}$				

Exemple 8.

Répartition des sociétaires assurés.

	Répartition du patrimoine mobilier							
	[0, 50[	[50, 100[	[100, 200[					
UH	25	75	150	$n_{i\bullet}$	B_i	D_i	Moyenne	Variance
0	870	970	650	2490	192000	20625000	77.11	2337.42
1	180	950	1820	2950	348750	46406250	118.22	1754.88
2	30	150	450	630	79500	10987500	126.19	1516.44
$n_{\bullet j}$	1080	2070	2920	6070	620250	78018750	102.18	2411.83
A_j	240	1250	2720	4210				
C_j	300	1050	3620	4970				
Moyenne	0.22	0.60	0.93	0.69				
Variance	0.23	0.15	0.37	0.34				

La moyenne du patrimoine immobilier est $\bar{y} = 102.18$ et la moyenne par unité d'habitation est $\bar{x} = 0.69$.
 La variance du patrimoine immobilier est $\sigma_y^2 = 2411.83$ et la variance par unité d'habitation est $\sigma_x^2 = 0.34$.
 La moyenne pour les sociétaires possédant une unité d'habitation est $\bar{y}_{|_2} = 118.22$.
 Pour les sociétaires ayant entre 100 et 200 milliers d'euros de patrimoine immobilier, la moyenne est $\bar{x}_{|_3} = 0.93$.

5.4. Covariance et coefficient de corrélation linéaire

- **Covariance du couple** (X, Y)

$$\text{Cov}(X, Y) = \sum_{\substack{1 \leq i \leq p \\ 1 \leq j \leq q}} f_{ij} (x_i - \bar{x})(y_j - \bar{y}) = \sum_{\substack{1 \leq i \leq p \\ 1 \leq j \leq q}} f_{ij} x_i y_j - \bar{x} \bar{y}.$$

Si X et Y sont **indépendants**, alors la covariance du couple (X, Y) est **nulle**.

- **Coefficient de corrélation linéaire**

$$r(X, Y) = \frac{\text{Cov}(X, Y)}{\sigma_x \sigma_y}.$$

Le coefficient de corrélation $r(X, Y)$ est toujours **compris** entre -1 et 1 .

Principe des calculs dans un tableau de contingence.

$\times$	y_j	Total	B_i	D_i	E_i
x_i	n_{ij}	$n_{i\bullet} = \sum_{j=1}^p n_{ij}$	$\sum_{j=1}^p n_{ij} \cdot y_j$	$\sum_{j=1}^p n_{ij} \cdot y_j^2$	$E_i = x_i \cdot B_i$
Total	$n_{\bullet j} = \sum_{i=1}^p n_{ij}$	N	B	D	E
A_j	$\sum_{i=1}^p n_{ij} \cdot x_i$	A			
C_j	$\sum_{i=1}^p n_{ij} \cdot x_i^2$	C			
E_j	$E_j = y_j \cdot A_j$	E			

$$r = \frac{E - \frac{AB}{N}}{\sqrt{C - \frac{A^2}{N}} \sqrt{D - \frac{B^2}{N}}} \quad \text{et} \quad \text{Cov}(X, Y) = \frac{E}{N} - \frac{A}{N} \times \frac{B}{N}$$

Exemple 9.

Répartition des sociétaires assurés.

	Répartition du patrimoine mobilier						
	[0, 50[	[50, 100[	[100, 200[				
UH	25	75	150	$n_{i\bullet}$	B_i	D_i	E_i
0	870	970	650	2490	192000	20625000	0
1	180	950	1820	2950	348750	46406250	348750
2	30	150	450	630	79500	10987500	159000
$n_{\bullet j}$	1080	2070	2920	6070	620250	78018750	507750
A_j	240	1250	2720	4210			
C_j	300	1050	3620	4970			
E_j	6000	93750	408000	507750			

5.5. Ajustement linéaire

Nous voulons ajuster la distribution de (X, Y) à une fonction linéaire ou affine $Y = aX + b$. Cet ajustement s'appelle la régression linéaire de Y en X . On définit de même $X = a'Y + b'$ comme la régression linéaire de X en Y .

- La **droite d'ajustement linéaire** ou **affine** passe par le point moyen $(\bar{x}, \bar{y})$.
- La **pente** de la droite d'ajustement linéaire de Y en X est

$$a = \frac{\text{Cov}(X, Y)}{\text{Var}(X)}.$$

- La **pente** de la droite d'ajustement linéaire de X en Y est

$$a' = \frac{\text{Cov}(X, Y)}{\text{Var}(Y)}.$$

Remarque.

- $r^2(X, Y) = a \times a'$.
- L'ajustement est **considéré significatif** si le coefficient $|r(X, Y)|$ est **supérieur ou égal à 0.7**.

Mini-exercices.

À l'oral du CAPES de mathématiques, chaque candidat est interrogé à l'épreuve d'exposé où il obtient la note X et à l'épreuve sur dossier où il obtient la note Y (notes sur 20). Les résultats obtenus par 104 candidats sont donnés dans le tableau ci-dessous :

$X \backslash Y$	$[0, 4[$	$[4, 8[$	$[8, 12[$	$[12, 16[$	$[16, 20[$
$[0, 4[$	1	1			
$[4, 8[$	1	3	5	11	
$[8, 12[$	2	10	10	28	
$[12, 16[$		1	3	9	11
$[16, 20[$			2	4	2

- Calculez la moyenne de X , de Y , l'écart-type de X et de Y .
- Donnez la distribution marginale des effectifs de X et de Y .
- Calculez la fréquence conditionnelle de $X \in [12, 16[$ sachant $Y \in [4, 8[$.
- Calculez la covariance de X et de Y puis déduisez-en le coefficient de corrélation.